

## ভেক্টর ও ভেক্টর স্পেস কী ছিল?

প্রথম দিনে আমরা শিখেছি ভেক্টর এবং ভেক্টর স্পেস।

- ভেক্টর হলো এমন একটি বস্তু যার মান (magnitude) ও দিক (direction) থাকে।
- উদাহরণ:
  - 2D তে: (3, 4)
  - 3D তে: (1, -2, 5)

একটি ভেক্টর স্পেস হলো এমন একটি জায়গা যেখানে:

- ভেক্টর যোগ করা যায়
- স্কেলার দিয়ে গুণ করা যায়
- কিছু নির্দিষ্ট নিয়ম মানা হয়

সহজভাবে বললে, এটা একটা গাণিতিক জগৎ যেখানে ভেক্টরগুলো থাকে।

## Linear Transformation কী?

এখন বলা হচ্ছে:

A Linear Transformation is a function that maps vectors from one space to another.

মানে,

একটি **Linear Transformation** হলো এমন একটি ফাংশন যা:

- একটি ভেক্টর স্পেস থেকে
- আরেকটি ভেক্টর স্পেসে
- ভেক্টরকে ম্যাপ (রূপান্তর) করে।

সহজ ভাষায়:

ধরো তুমি একটা ভেক্টর (2,1) নিলে।

এখন একটা নিয়ম প্রয়োগ করলে সেটা হয়ে গেল (4,2)।

এই "নিয়ম"টাই হলো **Linear Transformation**।

## কেন একে “Linear” বলা হয়?

কারণ এটা দুইটা গুরুত্বপূর্ণ নিয়ম মানে:

① যোগের ক্ষেত্রে:

$$T(v + w) = T(v) + T(w)$$

২) স্কেলার গুণের ক্ষেত্রে:

$$T(c v) = c T(v)$$

মানে, transformation করলে গাণিতিক সম্পর্ক নষ্ট হয় না।

## Matrix কীভাবে কাজ করে?

কনটেন্টে বলা হয়েছে:

A Matrix is the numerical engine that performs this transformation.

মানে,

**Matrix** হলো সেই সংখ্যার মেশিন যা **Linear Transformation** সম্পাদন করে।

উদাহরণ:

ধরো ম্যাট্রিক্স:

$$\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

$$\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

এটা যদি ভেক্টর  $(x, y)$  কে গুণ করি:

$$\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 2x \\ 2y \end{bmatrix}$$

$$\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 2x \\ 2y \end{bmatrix}$$

মানে ভেক্টর দ্বিগুণ হয়ে গেল।

এখানে ম্যাট্রিক্সটা space-কে "stretch" করছে।

## Matrix আসলে space-কে কী করে?

Matrix space-কে:

- Stretch করে (বড় করে)
- Compress করে (ছোট করে)
- Rotate করে (ঘুরিয়ে দেয়)
- Shear করে (বাঁকা করে দেয়)

- Reflect করে (উল্টে দেয়)

মানে পুরো জ্যামিতিক জায়গাটাকে পরিবর্তন করে দেয়।

## Deep Neural Networks এর সাথে সম্পর্ক কী?

এখানে সবচেয়ে গুরুত্বপূর্ণ অংশ:

Understanding how matrices morph space is the fundamental prerequisite for understanding how Deep Neural Networks manipulate data.

Deep Neural Network (DNN) এ যা হয়:

- Input data  $\rightarrow$  ভেক্টর আকারে থাকে
- প্রতিটি layer এ  $\rightarrow$  Matrix multiplication হয়
- তারপর activation function প্রয়োগ হয়

মানে পুরো Neural Network আসলে:

Matrix  $\times$  Vector + Activation

প্রতিটি layer একটা Linear Transformation করছে।

# 1 Linear Transformations

## 1.1 Functions in Higher Dimensions

সাধারণ ক্যালকুলাসে কী হয়?

আমরা জানি:

$f(x)$

এখানে,

- ইনপুট = একটি সংখ্যা
- আউটপুট = আরেকটি সংখ্যা

উদাহরণ:

$$f(x) = 2x$$

যদি  $x = 3$  হয়  $\rightarrow$  আউটপুট = 6

এটা  $1D \rightarrow 1D$  ম্যাপিং।

## কিন্তু **Linear Algebra** তে কী হয়?

এখানে ইনপুট একটা সংখ্যা না, বরং একটা ভেক্টর।

$T(x)$

এখানে:

- ইনপুট = একটি ভেক্টর
- আউটপুট = আরেকটি ভেক্টর

## $R^n \rightarrow R^m$ মানে কী?

$T : R^n \rightarrow R^m$

এটা খুব গুরুত্বপূর্ণ।

- $R^n = n$ -ডাইমেনশনের ভেক্টর স্পেস
- $R^m = m$ -ডাইমেনশনের ভেক্টর স্পেস

উদাহরণ:

- $R^2 \rightarrow R^2$   
(2D ভেক্টর থেকে 2D ভেক্টর)
- $R^3 \rightarrow R^2$   
(3D ভেক্টর থেকে 2D ভেক্টর)
- $R^{10} \rightarrow R^3$   
(10 feature থেকে 3 feature)

সহজ উদাহরণ

ধরো:

$$T(x,y) = (2x, 3y)$$

এখানে:

- ইনপুট:  $(x,y)$
- আউটপুট:  $(2x,3y)$

মানে space কে stretch করা হচ্ছে।

## 1.2 The Rules of Linearity

সব transformation linear না।

Linear হতে হলে ২টা কঠোর নিয়ম মানতে হবে।

### Rule 1: Additivity

$$T(u + v) = T(u) + T(v)$$

মানে:

## প্রথমে যোগ করে **transform** করা

আলাদা আলাদা transform করে পরে যোগ করা

উদাহরণ:

ধরো:

$$T(x,y) = (2x, 2y)$$

$$u = (1,1)$$

$$v = (2,0)$$

তাহলে:

$$u + v = (3,1)$$

$$T(u+v) = (6,2)$$

এখন আলাদা করলে:

$$T(u) = (2,2)$$

$$T(v) = (4,0)$$

যোগ করলে:

$$(6,2)$$

✓ একই ফল  $\rightarrow$  তাই additivity ঠিক আছে

## Rule 2: Homogeneity

$$T(cu) = cT(u)$$

মানে স্কেলার বাইরে আসতে পারবে।

উদাহরণ:

$$u = (1,2)$$

$$c = 3$$

$$cu = (3,6)$$

$$T(3,6) = (6,12)$$

অন্যদিকে:

$$T(1,2) = (2,4)$$

$$3T(1,2) = (6,12)$$

✓ একই ফল  $\rightarrow$  homogeneity ঠিক আছে

## জ্যামিতিক অর্থ

এখন আসল গভীর বিষয়

১ **Origin (0)** স্থির থাকতে হবে

$$T(0) = 0$$

মানে (0,0) পয়েন্ট নড়তে পারবে না।

যদি origin সরে যায়  $\rightarrow$  transformation linear না।

কারণ:

Linear transformation শুধু stretch, rotate, shear করতে পারে  
কিন্তু shift করতে পারে না।

উদাহরণ (**Linear** না)

$$T(x,y) = (x+1, y)$$

এখানে:

$$T(0,0) = (1,0)$$

Origin সরে গেছে **✗**  
তাই এটা linear না।

## ২ Grid lines parallel থাকতে হবে

এটা খুব সুন্দর জ্যামিতিক ধারণা।

ধরো 2D grid:

||||  
----  
||||

Linear transformation করলে:

- লাইনগুলো বাঁকা হতে পারে
- stretch হতে পারে
- rotate হতে পারে

কিন্তু:

- ✓ সমান্তরাল থাকবে
- ✓ সমান দূরত্ব বজায় রাখবে

যদি grid বেঁকে অসমান হয়ে যায় → linear না।

## গভীরভাবে বোঝো

Linear transformation পারে:

- Stretch
- Compress
- Rotate
- Reflect
- Shear

কিন্তু পারে না:

- Shift (translate)
- Curve বানাতে

## Deep Learning এর সাথে সম্পর্ক

Neural Network এ প্রতিটি layer:

$$T(x) = Wx$$

এখানে  $W$  হলো matrix।

প্রতিটি layer একটা Linear Transformation।

তারপর activation function যোগ হয়

## 2 Matrices as Functions



## 2.1 The Transformation Matrix

মূল কথা:

প্রতিটি **Linear Transformation** কে একটি **Matrix** দিয়ে পুরোপুরি প্রকাশ করা যায়।

মানে —

যদি transformation linear হয়, তাহলে সেটা সবসময় একটা matrix multiplication দিয়ে করা সম্ভব।

## Basis Vector দিয়ে পুরো Space বোঝা

2D space—এ দুইটা বিশেষ ভেক্টর আছে:

$$e_1 = (1, 0)$$

$$e_2 = (0, 1)$$

এগুলোকে বলে **basis vectors**।

এরা হলো পুরো space—এর building blocks।

যেকোনো ভেক্টর লেখা যায় এভাবে:

$$x = x_1 e_1 + x_2 e_2$$

মানে,

$$(x_1, x_2)$$

আসলে হলো:

$$x_1(1, 0) + x_2(0, 1)$$

## গুরুত্বপূর্ণ ধারণা:

যদি আমরা জানি:

- $T(e_1)$  কোথায় যায়
- $T(e_2)$  কোথায় যায়

তাহলে আমরা পুরো space কোথায় যাচ্ছে সেটা জেনে ফেলেছি।

কারণ সব ভেক্টরই  $e_1$  আর  $e_2$  দিয়ে তৈরি।

## Transformation Matrix তৈরি করা

ধরো:

$$T(e_1) = (a, c)$$

$$T(e_2) = (b, d)$$

তাহলে matrix হবে:

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

⚡ লক্ষ্য করো:

- প্রথম column =  $T(e_1)$
- দ্বিতীয় column =  $T(e_2)$

এটাই transformation matrix।

## এখন যেকোনো ভেক্টর **transform** করা

ধরো:

$$x = (x_1, x_2)$$

তাহলে:

$$Ax =$$

$$\begin{bmatrix} a & b \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\begin{bmatrix} c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

গুণ করলে:

$$= (ax_1 + bx_2, \\ cx_1 + dx_2)$$

## গভীরভাবে বোঝো

এর মানে:

$$Ax = x_1T(e_1) + x_2T(e_2)$$

মানে matrix আসলে বলছে:

"তুমি basis vector গুলোকে যেভাবে সরিয়েছো,  
আমি সেই অনুযায়ী পুরো space বানিয়ে দিচ্ছি।"

## জ্যামিতিক অর্থ

Matrix কী করছে?

- $e_1$  কে সরাচ্ছে
- $e_2$  কে সরাচ্ছে
- তারপর পুরো grid সেই অনুযায়ী deform করছে

এজন্য matrix মানেই space warping machine 🔥

## ছোট একটা বাস্তব উদাহরণ

ধরো:

$$T(e_1) = (2,0)$$

$$T(e_2) = (0,3)$$

তাহলে matrix:

$$\begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$$

এটা:

- x direction কে 2 গুণ করছে
- y direction কে 3 গুণ করছে

মানে rectangle stretch হয়ে যাবে।

## Neural Network—এর সাথে সংযোগ

এখানে বলা হয়েছে:

$$z = Wx + b$$

এটা একটি dense layer।

এখানে:

- $x$  = input vector
- $W$  = weight matrix
- $b$  = bias
- $z$  = output

### **W** কী করছে?

$W$  হচ্ছে transformation matrix।

এটা input space—কে warp করছে।

মানে:

- Data কে stretch করছে
- rotate করছে
- shear করছে
- dimension বাড়াতে/কমাতে পারে

সব মিলিয়ে pattern আলাদা করা সহজ করছে।

### **Bias (b)** কী করছে?

আগে বলেছিলাম:

Linear transformation origin সরতে পারে না।

কিন্তু Neural Network এ:

$$z = Wx + b$$

এই  $+b$  origin সরিয়ে দেয়।

মানে এটা pure linear না —

এটা আসলে **Affine Transformation**।

## Deep Insight

Neural Network layer =

- ① Linear transformation ( $W$ )
- ② Translation ( $b$ )
- ③ Non-linearity (activation function)

Repeated many times  $\rightarrow$  complex pattern separation

## ③ Matrix Operations and Composition

### 3.1 Matrix Multiplication

**Transformation** একটার পর একটা করলে কী হয়?

ধরো তুমি:

- ① আগে Transformation **B** করলে
- ② তারপর Transformation **A** করলে

তাহলে চূড়ান্ত ফল হবে একটি নতুন transformation **C**।

গাণিতিকভাবে:

$$C = AB$$

⚠️ খেয়াল করো:

আগে B, তারপর A  
কিন্তু লেখা হয় AB  
(ডানদিকেরটা আগে কাজ করে)

## সাইজ (Dimension) নিয়ম

যদি:

- A এর size =  $m \times n$
- B এর size =  $n \times p$

তাহলে:

- $C = AB$  হবে  $m \times p$

কারণ মাঝের  $n$  মিলতে হবে।

## $C_{ij}$ কিভাবে বের হয়?

C এর  $i$ -তম row আর  $j$ -তম column বের করতে:

$$C_{ij} = \sum (A_{ik} B_{kj})$$

মানে:

A এর  $i$ -তম row  
dot product  
B এর  $j$ -তম column

ছোট উদাহরণ

ধরো:

A =

[1 2]

[3 4]

B =

[5 6]

[7 8]

তাহলে  $C_{11}$  হবে:

$$(1 \times 5 + 2 \times 7) = 5 + 14 = 19$$

এইভাবেই পুরো matrix তৈরি হয়।

## জ্যামিতিক অর্থ

Matrix multiplication মানে:

এক transformation এর উপর আরেক transformation বসানো।

যেমন:

- আগে rotate করলে
- তারপর stretch করলে

এটা একসাথে করলে আলাদা ফল আসবে।

## খুব গুরুত্বপূর্ণ নিয়ম

**Matrix multiplication commutative** না

$$AB \neq BA$$

মানে:

আগে rotate তারপর shear

$\neq$

আগে shear তারপর rotate

ক্রম বদলালে ফল বদলে যায়।

বাস্তব উদাহরণ

ধরো:

- একটা ছবি  $90^\circ$  ঘুরালে
- তারপর ডানদিকে টানলে (shear)

ফল একরকম।

কিন্তু আগে shear করলে

তারপর rotate করলে

সম্পূর্ণ ভিন্ন ফল আসবে।

এটাই non-commutativity।

## 3.2 Identity and Inverses

### Identity Matrix (I)

Identity matrix হলো matrix জগতের সংখ্যা 1।

যেমন:

$$I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

এটা দিয়ে গুণ করলে কিছুই বদলায় না।

$$Ix = x$$

মানে space অপরিবর্তিত থাকে।

জ্যামিতিকভাবে

Identity transformation =

কোনো পরিবর্তন না।



# Inverse Matrix ( $A^{-1}$ )

Inverse হলো এমন matrix যা আগের transformation পুরোপুরি undo করে।

$$A^{-1}A = I$$

$$AA^{-1} = I$$

## উদাহরণ

ধরো:

$A = 90^\circ$  clockwise rotation

তাহলে:

$A^{-1} = 90^\circ$  counter-clockwise rotation

মানে একে অন্যকে বাতিল করে দেয়।

# Deep Geometric Insight

Matrix যদি:

- rotate করে
- stretch করে
- shear করে

তাহলে inverse matrix:

- উল্টো দিকে rotate করবে
- $1/\text{scale}$  দিয়ে shrink করবে
- উল্টো shear করবে

## সব matrix এর inverse নেই

যদি matrix space কে flatten করে ফেলে  
(যেমন  $2D \rightarrow \text{line}$  বানিয়ে ফেলে)

তাহলে information হারিয়ে যায়  
→ inverse সম্ভব না।

এমন matrix কে বলে singular matrix।

## Neural Network এর সাথে সম্পর্ক

Neural Network এ:

$$z = Wx + b$$

একাধিক layer থাকলে:

$$z = W_3 W_2 W_1 x$$

মানে:

Multiple transformations compose হয়ে যাচ্ছে।

এটাই matrix multiplication।

## 4 Systems of Linear Equations

### Matrix আকারে লেখা

একটা লিনিয়ার সমীকরণ সিস্টেমকে আমরা compact ভাবে লিখতে পারি:

$$Ax = b$$

এখানে:

- **A** = coefficient matrix (transformation)
- **x** = অজানা ভেক্টর (unknowns)
- **b** = target/output ভেক্টর

উদাহরণ দিয়ে বোঝি

ধরো সমীকরণ:

$$2x + y = 5$$

$$x - y = 1$$

এটা matrix আকারে:

$$\begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} x \end{bmatrix} = \begin{bmatrix} 5 \end{bmatrix}$$

$$\begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} y \end{bmatrix} = \begin{bmatrix} 1 \end{bmatrix}$$

মানে:

$$Ax = b$$

## 4.1 Geometric Interpretation

এটাই সবচেয়ে গুরুত্বপূর্ণ অংশ

সমীকরণটা আসলে জিওমেট্রি করছে:

কোন ভেক্টর  $x$  কে transformation  $A$  এর মাধ্যমে পাঠালে  
ঠিক  $b$  তে গিয়ে পৌঁছাবে?

মানে:

$$A(x) = b$$

জ্যামিতিকভাবে কী হচ্ছে?

Matrix  $A$  পুরো space কে warp করছে।

তুমি এমন একটা  $x$  খুঁজছো,  
যাকে warp করলে ঠিক  $b$  পাওয়া যায়।

**2D** কল্পনা করো

- x হলো input arrow
- A হলো space warping machine
- b হলো target arrow

তাহলে প্রশ্ন:

কোন arrow দিলে,  
machine সেটাকে ঠিক b বানাবে?

## যদি **A invertible** হয়

যদি matrix A:

- space flatten না করে
- dimension কমিয়ে না ফেলে
- information না হারায়

তাহলে এর inverse থাকবে।

তখন সমাধান খুব সহজ:

$$A^{-1}Ax = A^{-1}b$$

কারণ:

$$A^{-1}A = I$$

তাহলে:

$$Ix = A^{-1}b$$

মানে:

$$x = A^{-1}b$$

## জ্যামিতিক অর্থ

b-কে উল্টো transformation দিয়ে ফেরত পাঠালেই x পাওয়া যায়।

মানে:

Forward:  $A$

Backward:  $A^{-1}$

## যদি $A$ invertible না হয়?

তখন তিনটা অবস্থা হতে পারে:

- ❶ কোনো সমাধান নেই
- ❷ অসীম সমাধান আছে
- ❸ unique solution নেই

কারণ transformation space কে collapse করেছে।

যেমন:

$2D \rightarrow \text{line}$  বানিয়ে ফেললে

আসল  $2D$  point recover করা যাবে না।

## Machine Learning—এ এর গুরুত্ব

ধরো Linear Regression:

$$Xw = y$$

এখানে:

- $X$  = data matrix
- $w$  = weights
- $y$  = output

আমরা  $w$  খুঁজছি।

তাত্ত্বিকভাবে:

$$w = (X^T X)^{-1} X^T y$$

কিন্তু সমস্যা হলো:

Matrix inverse বের করা খুব ব্যয়বহুল।

## কেন **inverse compute** করা খারাপ ধারণা?

Inverse বের করতে সময় লাগে প্রায়:

$$O(n^3)$$

মানে dimension বড় হলে computation explode করে।

আরও বড় সমস্যা:

Numerical instability।

ছোট rounding error  $\rightarrow$  বড় error হয়ে যেতে পারে।

## তাই বাস্তবে কী করা হয়?

Direct inverse না করে:

- ✓ Gradient Descent
- ✓ LU Decomposition
- ✓ QR Decomposition
- ✓ SVD

ব্যবহার করা হয়।

## **Gradient Descent** কী করছে আসলে?

এটা inverse বের করছে না।

বরং iterative ভাবে এমন  $x$  খুঁজছে  
যাতে  $Ax \approx b$  হয়।

# Deep Insight (খুব গুরুত্বপূর্ণ)

Linear algebra বলছে:

$\text{Solution} = \text{Inverse} \times \text{Target}$

Machine Learning বলছে:

Direct inverse কোনো না।

Optimization দিয়ে solution খুঁজো।